



廣州南方學院

NANFANG COLLEGE · GUANGZHOU

学生实验（实训、实践） 报告

项目名称：网页信息提取与数据化

学院名称：设计学院

专业班级：24 数字媒体艺术游戏班

学生学号：XXXX

学生姓名：XXXX

授课教师：林昕

实验日期: XXXX

实验报告说明

1. 实验报告应包含实验目的、实验条件、实验方法、实验内容、结果分析、成绩评定等内容，本模板已有部分为建议架构，各单位可根据专业及课程特点调整报告内容。
2. 学生应认真撰写实验内容，并对实验进行总结分析。
3. 指导教师应严格依照成绩评定标准对实验报告进行成绩评定并签字，评语围绕实验报告内容，具体、有针对性、有建设性。
4. 格式要求：A4 幅面，双面打印。**封面：**汉字采用三号宋体、外文数字采用三号 Times New Roman 体，下划线居中填写，下划线整体长度不改变；**正文：**汉字采用小四号宋体、外文数字采用小四

号 Times New Roman 体；左对齐填写，首行缩进 2 字符，行距固定

值 20 磅，图或表的字体大小为五号字。

实验地点：	温泉校区 3 实 208	指导教师：	林昕
同组人员：	XXXX		
一、实验目的 (一) 掌握利用爬虫脚本或大语言模型（LLM）从网页中提取信息的策略。 (二) 能够清洗与整理非结构化信息，输出规范的结构化数据集（如 CSV / JSON）。 (三) 理解“从信息到数据”的预处理流程对后续可视化分析的决定性作用。			
二、实验条件（环境） 1. 硬件：个人计算机 2. 软件：现代浏览器（推荐 Chrome 或 Edge）、大语言模型辅助工具（如 ChatGPT、Claude 或 VSCode Agent）			
三、实验方法（原理） 1. 确定数据来源与分析规律：结合个人兴趣自主选定目标网页（严禁使用“豆瓣读书”等教学案例），并重点观察和归纳翻页时 URL 参数的路由变化规律。避开无限下拉瀑布流网页。 2. 获取结构模板：将目标网页右键“另存为”完整的本地 HTML 文件。 3. 方案执行：将 HTML 模板和 URL 翻页规律提交给大模型（Agent），要求其生成用于浏览器后台（Console）运行的 JavaScript 爬虫脚本。 3. 数据清洗：处理缺失值、格式化字段格式，导出为 CSV 或 JSON 文件。 4. 撰写流程记录与心得。			
四、实验内容（步骤） XXXX			
五、实验结果分析 XXXX			
六、成绩评定			

评 语：
{{comment}}

评分： {{score}}

指导教师签字： {{sign}}