

网页信息提取与数据化

实践项目：网页信息提取与数据化 — 实验指导书

实验类型：设计性

实验学时：标准学时

每组人数：1 人

开出要求：必做

致数字媒体艺术同学的导言 在进行信息可视化之前，我们需要有“数据”。很多时候我们想要的

数据跨越了网页的好几页（比如排行榜前 10 页）。
在本实验中，请把浏览器当成“舞台”，把浏览器的 **F12 控制台（Console）** 当成“后台”。你的角色是导演，大语言模型（如 VSCode Agent/ChatGPT/Claude 等）是你的编剧。你只需要做两件事：帮 AI 探明翻页规律，并把网页的源码图纸（本地 **HTML**）交给 AI。接下来，AI 就会为你写好“后台执行脚本”，帮你自动抓取数据。

⚠️【重要扩展要求】：严禁在本实验中使用“豆瓣读书”作为抓取目标！请务必结合你的个人兴趣选定跨领域目标（游戏、电影、电商等），发挥你探索世界的能力。

一、实验目的

（一）掌握跨领域寻找数据源的能力，建立业务导向的抓取思维。（二）掌握网页 URL 路由翻页规律的观察与归纳方法，提升基础数据素养。（三）掌握将网页结构转化为大模型认知素材的方法（另存为本地 HTML 模板）。（四）掌握利用大语言模型编写浏览器后台爬虫脚本的策略，并理解浏览器 Cookie 穿透的反爬虫优势。

（五）体会“人机协作”的过程，学会如何利用通用提示词模板和报错反馈引导 AI 完成任务。

二、实验设备与环境

- 硬件：个人计算机
- 软件：现代浏览器（强烈推荐 Chrome 或 Edge）、大语言模型辅助工具

三、实验步骤与要点（四大战役）

战役 1：侦查翻页规律（路由特征分析）

- 选定你的专属目标网页：

- 💡 选题灵感库：你可以选择 Steam 游戏热销榜、IMDB 电影排行、淘宝/京东商品列表、汽车之家报价、懂车帝、Bilibili 视频榜单等。

🔴 **【避坑声明（极其重要）】**：并非所有网页都适合这种基础抓取。如果一个网站是“瀑布流（无限下拉自动加载更多）”（比如抖音、小红书），请立即放弃并更换目标！你必须选择那种有明确的“下一页”按钮、且点击后网址会发生改变的传统网页。

2. 侦查翻页规律（极其重要!!!）：

- 网页只会把第一页给你看。如果你不告诉 AI 第二页的网址怎么变，AI 写出的代码就无法翻页。
- 在网页上手动点击“下一页”或“第 2 页”。仔细观察浏览器顶部的网址栏（URL）。
- 比如：某网站第一页是 ?start=0，第二页变成了 ?start=25。你需要把这个规律记下来，这是稍后必须交给 AI 的关键情报。

战役 2：获取网页“建筑图纸”（下载本地 HTML 模板）

AI 如果不看网页的内部结构，是写不出准确抓取代码的。我们需要给它一张图纸：1. 回到你要抓取的第一页。2. 在该网页的空白处点击鼠标右键，选择“另存为”（Save as...）。3. 确保保存类型选择为网页，仅 HTML (Webpage, HTML Only)，将这个 HTML 文件保存到你的电脑中。

战役 3：指挥大模型（与 AI 沟通获取代码）

打开你的大模型 AI，把 **【你侦查到的翻页规律】** 和 **【HTML 图纸】** 组合在一起，向 AI 下达指令。

🌟 魔法提示词通用模板（请务必将括号内内容替换为你的专属目标）：

（第一步：上传附件，或拖入刚刚保存的 HTML 文件让 AI 读取）

请帮我编写一段原生 JavaScript 脚本，用于在 Chrome 浏览器的 Console (控制台) 里直接运行。目标：提取多页数据并最终自动合并下载为一个 CSV 文件。

【1. 网页结构分析】 请读取我上传的本地 HTML 文件附件（这是目标网页的源码），请你自动识别并提取以下目标字段的 DOM 选择器规律：- 字段1：[比如：游戏名称] - 字段2：[比如：玩家评分] - 字段3：[比如：近期价格]

【2. 分页抓取规律】 - 目标基础网址：[填入你的目标基础URL，如 https://store.steampowered.com/search/] - 分页路由规律：[共需抓取 3 页。URL 参数规律为 ?page=1, ?page=2 (每页步长为 1)]

【3. 执行与防封要求】 在循环抓取每一页时，请务必加入 2-3 秒的随机延迟等待页面加载。执行时请在 Console 打印出当前抓取的页码和进度，让我知道脚本没有卡死。

战役 4：深入后台，执行与除错（运行与调试代码）

💡 **【专家级技巧：Cookie 穿透】** 我们在 Console 跑脚本的最大优势，就是它可以借用你的身份。在执行脚本前，请先在目标网站登录你的个人账号。这样脚本请求数据时会带着

你的合法 Cookie，极大地降低被反爬虫系统拦截的概率！

1. 进入后台：在你的目标在线网页，按下 F12（Mac 为 Option + Command + I），找到 **Console**（控制台）。
2. 运行剧本：将 AI 生成的代码粘贴到 Console 最下方闪烁的光标处，按下 Enter（回车键）。
3. 极简 **Debug** 循环：
 - 如果出现了红色的报错信息（Error），绝对不要慌。复制报错文字，丢回给 AI 说：“刚刚的代码报错了，错误信息是这段，请帮我修复代码并重新给我一份。”反复循环即可。

清洗战利品（数据清洗与规范化输出）

拿到 CSV 后，用 Excel 或 Numbers 打开它进行数据清洗：- 剔除 NaN、空白残缺数据，删除不需要的货币符号（如 ¥、\$），只保留能用来计算画图的纯数字。

四、实验结论

完成操作后，请在报告中反思：1. 为什么浏览器 Console 运行脚本比独立写 Python 爬虫更容易规避反爬拦截？2. 脏数据的清洗对最终图表的准确性有多大影响？